

Integral Image Generator

Parallel Programming for Machine Learning Project Work in Artificial Intelligence Programming

Sofia Galante



Introduzione

Il progetto svolto è un generatore di immagini integrali. In un'immagine integrale, data un'immagine di partenza, ogni pixel è ottenuto sommando se stesso con tutti i pixel precedenti (sia lungo l'asse x che lungo l'asse y). Si sono creati diversi generatori di immagini integrali:

- un generatore sequenziale: in questo caso si generano le immagini integrali con un algoritmo sequenziale;
- due versioni di un generatore con CUDA: in questo caso si utilizza la *GPU* per parallelizzare la creazione dell'immagine integrale;
- tre versioni di un generatore con OpenMP: in questo caso si compie una parallelizzazione a livello della *CPU* del codice tramite OpenMP.

Lo scopo del progetto è quello di osservare lo speedup ottenuto nelle due versioni parallele dell'algoritmo, osservando anche quale parallelizzazione (tra GPU e CPU) risulta più efficiente.

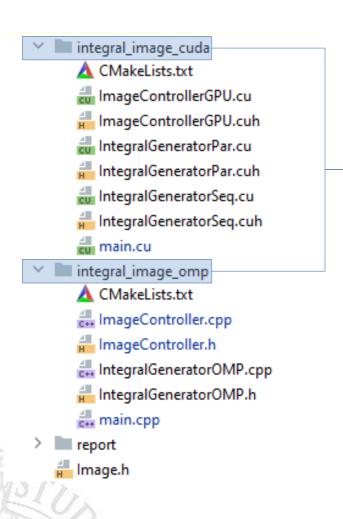
Tutti gli esperimenti sono stati svolti su un PC con sistema operativo Windows 10, una CPU Intel Core i5-11400 e una GPU RTX 3070Ti.

La versione sequenziale e quella parallelizzata a livello di GPU utilizzano Visual C++ come compilatore. Per quanto riguarda la versione con OpenMP, si è optato per l'utilizzo di MinGW.



- ✓ Imintegral_image_cuda
 - ▲ CMakeLists.txt
 - almageControllerGPU.cu
 - = ImageControllerGPU.cuh
 - all IntegralGeneratorPar.cu
 - 🚛 Integral Generator Par. cuh
 - IntegralGeneratorSeq.cu
 - 🚚 Integral Generator Seq. cuh
 - amain.cu
- integral_image_omp
 - ▲ CMakeLists.txt
 - # ImageController.cpp
 - # ImageController.h
 - all IntegralGeneratorOMP.cpp
 - IntegralGeneratorOMP.h
 - amain.cpp
- > report
 - 📇 lmage.h





due progetti diversi



- ✓ Imintegral_image_cuda
 - ▲ CMakeLists.txt
 - almageControllerGPU.cu
 - 📶 ImageControllerGPU.cuh
 - all IntegralGeneratorPar.cu
 - 🚛 Integral Generator Par. cuh
 - all IntegralGeneratorSeq.cu
 - # IntegralGeneratorSeq.cuh
 - main.cu
- integral_image_omp
 - ▲ CMakeLists.txt
 - all ImageController.cpp
 - # ImageController.h
 - all IntegralGeneratorOMP.cpp
 - IntegralGeneratorOMP.h
 - amain.cpp
- > report
 - 📶 lmage.h

contiene la definizione di immagine e il valore del SEED



integral_image_cuda ▲ CMakeLists.txt ImageControllerGPU.cu # ImageControllerGPU.cuh IntegralGeneratorPar.cu # IntegralGeneratorPar.cuh IntegralGeneratorSeq.cu IntegralGeneratorSeq.cuh amain.cu integral_image_omp ▲ CMakeLists.txt # ImageController.cpp # ImageController.h all IntegralGeneratorOMP.cpp IntegralGeneratorOMP.h amain.cpp report

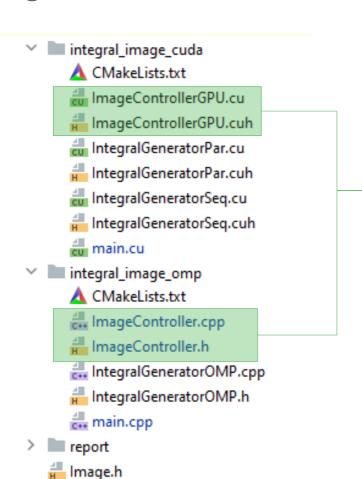
🚚 lmage.h

```
#ifndef SEED
#define SEED 111
#endif //SEED

#ifndef INTEGRAL_IMAGEOMP_IMAGE_H
#define INTEGRAL_IMAGEOMP_IMAGE_H

struct Image {
   int * pixels = nullptr;
   int width = 0;
   int height = 0;
};
#endif //INTEGRAL_IMAGEOMP_IMAGE_H
```





file che contengono le funzioni per gestire le immagini



amain.cpp

report

📇 lmage.h

```
__host__ Image generateImage(int width, int height);
__host__ Image copyImage(Image const &image);

__host__ Image allocateOnDevice(Image const &hostImage);
__host__ void freeImageHost(Image &hostImage);
__host__ void freeImageDev(Image &devImage);
__host__ void copyFromHostToDevice(Image const &hostImage, Image &devImage);
__host__ void copyFromDeviceToHost(Image const &devImage, Image &hostImage);
__host__ void printImage(Image const &image);
__host__ bool areTheSame(Image const &image1, Image const &image2);
```

```
Image generateImage(int width, int height);
Image copyImage(Image const &image);

void freeImage(Image &hostImage);

void printImage(Image const &image);
```



```
✓ Imintegral image cuda

     ▲ CMakeLists.txt
      almageControllerGPU.cu
     ImageControllerGPU.cuh
     IntegralGeneratorPar.cu
     IntegralGeneratorPar.cuh
     IntegralGeneratorSeq.cu
     IntegralGeneratorSeq.cuh
     amain.cu
integral_image_omp
     ▲ CMakeLists.txt
     almageController.cpp
     ImageController.h
     # IntegralGeneratorOMP.cpp
     IntegralGeneratorOMP.h
     amain.cpp
     report
   📇 lmage.h
```

```
__host__ Image generateImage(int width, int height);
__host__ Image copyImage(Image const &image);

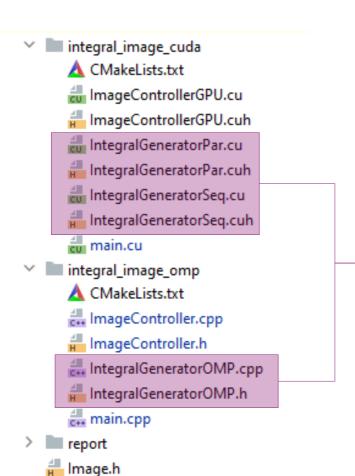
__host__ Image allocateOnDevice(Image const &hostImage);
__host__ void freeImageHost(Image &hostImage);
__host__ void freeImageDev(Image &devImage);
__host__ void copyFromHostToDevice(Image const &hostImage, Image &devImage);
__host__ void copyFromDeviceToHost(Image const &devImage, Image &hostImage);
__host__ void printImage(Image const &image);
__host__ bool areTheSame(Image const &image1, Image const &image2);
```

```
Image generateImage(int width, int height);
Image copyImage(Image const &image);

void freeImage(Image &hostImage);

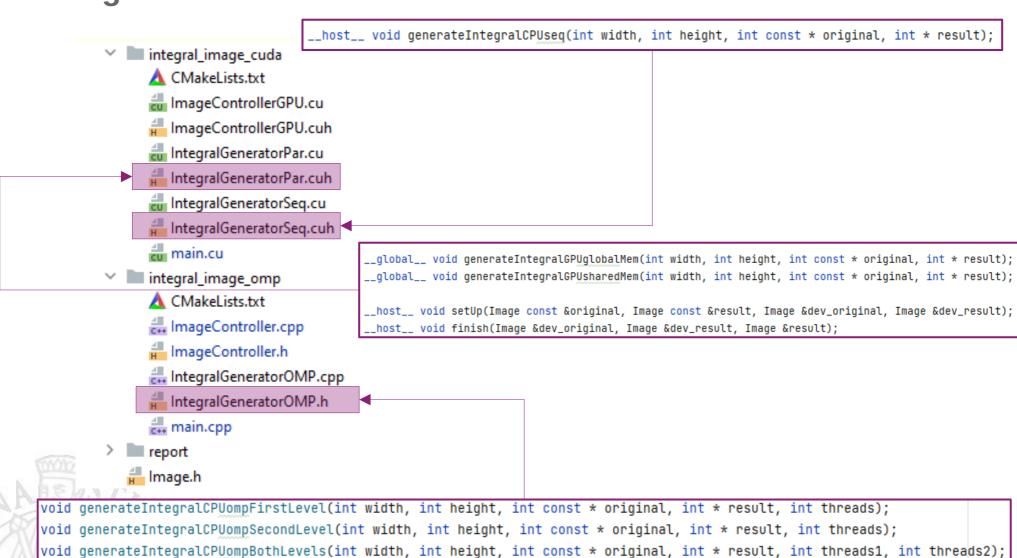
void printImage(Image const &image);
```





file che contengono le funzioni per generare le immagini integrali







Algoritmo sequenziale



```
__global__ void generateIntegralGPUglobalMem(int width, int height, int const * original, int * result){
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
    int ty = threadIdx.y;
    int row = by * blockDim.y + ty;
    int col = bx * blockDim.x + tx;
    int value = 0;
    if(col < width && row < height){
        for(int y = row; y >= 0; y--){
            for(int x = col; x >= 0; x--){
                value += original[y * width + x];
        result[row * width + col] = value;
```



```
__global__ void generateIntegralGPUglobalMem(int width, int height, int const * original, int * result){
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
                                                                  sostituisce i primi
    int ty = threadIdx.y;
                                                                        due for
    int row = by * blockDim.y + ty;
    int col = bx * blockDim.x + tx;
    int value = 0;
    if(col < width && row < height){
        for(int y = row; y >= 0; y--){
            for(int x = col; x >= 0; x--){
                value += original[y * width + x];
        result[row * width + col] = value;
```



```
__global__ void generateIntegralGPUglobalMem(int width, int height, int const * original, int * result){
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
                                                                       controllo per non
    int ty = threadIdx.y;
                                                                         andare fuori
                                                                        dall'immagine
    int row = by * blockDim.y + ty;
    int col = bx * blockDim.x + tx;
    int value = 0;
    if(col < width && row < height){
        for(int y = row; y >= 0; y--){
            for(int x = col; x >= 0; x--){
                value += original[y * width + x];
        result[row * width + col] = value;
```



```
]__global__ void generateIntegralGPUglobalMem(int width, int height, int const * original, int * result){
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
                                                                           accessi in
    int ty = threadIdx.y;
                                                                             global
                                                                            memory
    int row = by * blockDim.y + ty;
    int col = bx * blockDim.x + tx;
    int value = 0;
    if(col < width && row < height){
        for(int y = row; y >= 0; y--){
            for(int x = col; x >= 0; x--){
                value += original[y * width + x];
        result[row * width + col] = value;
```



```
__global__ void generateIntegralGPUsharedMem(int width, int height, int const * original, int * result)¶
    //Utilizzo della shared memory
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
    int ty = threadIdx.y;
    int w = blockDim.x;
    int h = blockDim.y;
    int row = by *h + ty;
    int col = bx * w + tx;
    extern __shared__ int sharedOriginal[];
    int value = 0;
    int _row, _col, _x, _y;
    for(int _by = 0; _by <= by; _by++){
        for(int _bx = 0; _bx <= bx; _bx++){ //itera tra i blocchi</pre>
            _{row} = _{by} * h + ty;
            _{col} = _{bx} * w + tx;
            if(_col < width && _row < height)
                sharedOriginal[ty * w + tx] = original[_row * width + _col];
            else
                sharedOriginal[ty * w + tx] = 0;
            __syncthreads();//ogni thread scrive nella shared memory e poi aspetta
```



```
__global__ void generateIntegralGPUsharedMem(int width, int height, int const * original, int * result)¶
    //Utilizzo della shared memory
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
                                                                     alloco dinamicamente
    int ty = threadIdx.y;
                                                                       la shared memory
    int w = blockDim.x;
    int h = blockDim.y;
    int row = by *h + ty;
    int col = bx * w + tx;
    extern __shared__ int sharedOriginal[]
    int value = 0;
    int _row, _col, _x, _y;
    for(int _by = 0; _by <= by; _by++){
        for(int _bx = 0; _bx <= bx; _bx++){ //itera tra i blocchi</pre>
            _{row} = _{by} * h + ty;
            _{col} = _{bx} * w + tx;
            if(_col < width && _row < height)
                sharedOriginal[ty * w + tx] = original[_row * width + _col];
            else
                sharedOriginal[ty * w + tx] = 0;
            __syncthreads();//ogni thread scrive nella shared memory e poi aspetta
```



```
__global__ void generateIntegralGPUsharedMem(int width, int height, int const * original, int * result)¶
    //Utilizzo della shared memory
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
    int ty = threadIdx.y;
    int w = blockDim.x;
    int h = blockDim.y;
    int row = by *h + ty;
                                                                                  divisione in fasi
    int col = bx * w + tx;
                                                                                   dell'algoritmo
    extern __shared__ int sharedOriginal[];
    int value = 0;
    int _row, _col, _x, _y;
    for(int _by = 0; _by <= by; _by++){
        for(int _bx = 0; _bx <= bx; _bx++){ //itera tra i blocchi</pre>
            _{row} = _{by} * h + ty;
            _{col} = _{bx} * w + tx;
            if(_col < width && _row < height)
                sharedOriginal[ty * w + tx] = original[_row * width + _col];
            else
                sharedOriginal[ty * w + tx] = 0;
            __syncthreads();//ogni thread scrive nella shared memory e poi aspetta
```



```
__global__ void generateIntegralGPUsharedMem(int width, int height, int const * original, int * result)¶
    //Utilizzo della shared memory
    int bx = blockIdx.x;
    int by = blockIdx.y;
    int tx = threadIdx.x;
    int ty = threadIdx.y;
    int w = blockDim.x;
    int h = blockDim.y;
    int row = by *h + ty;
                                                                                       copia i valori
    int col = bx * w + tx;
                                                                                  nella shared memory
    extern __shared__ int sharedOriginal[];
                                                                                           (tiling)
    int value = 0;
    int _row, _col, _x, _y;
    for(int _by = 0; _by <= by; _by++){
        for(int _bx = 0; _bx <= bx; _bx++){ //itera tra i blocchi</pre>
            _{row} = _{by} * h + ty;
            _{col} = _{bx} * w + tx;
            if(_col < width && _row < height)
                sharedOriginal[ty * w + tx] = original[_row * width + _col];
            else
                sharedOriginal[ty * w + tx] = 0;
            __syncthreads();//ogni thread scrive nella shared memory e poi aspetta
```



```
if(bx < bx)
            _x = w-1;
        else{
            _x = tx;
        if(_by < by){
            _{y} = h-1;
        else{
            _y = ty;
        if(col < width && row < height){</pre>
            for(int y = _y; y >= 0; y--){
                for(int x = _x; x >= 0; x--){
                     value += sharedOriginal[y * w + x];
        __syncthreads();
if(col < width && row < height)</pre>
    result[row * width + col] = value;
```



```
if(bx < bx)
            _x = w-1;
                                                 determina quali
                                                  valori sono da
        else{
                                                     utilizzare
            _x = tx;
        if(_by < by){
            _{y} = h-1;
       else{
            _y = ty;
        if(col < width && row < height){
            for(int y = _y; y >= 0; y--){
                for(int x = _x; x >= 0; x--){
                    value += sharedOriginal[y * w + x];
        __syncthreads();
if(col < width && row < height)</pre>
    result[row * width + col] = value;
```



```
if(bx < bx)
            _{x} = w-1;
        else{
            _x = tx;
                                                                    calcolo parziale
        if(_by < by){
                                                                        del valore
            _{y} = h-1;
                                                                         cercato
        else{
            _y = ty;
        if(col < width && row < height){
            for(int y = _y; y >= 0; y--){
                for(int x = _x; x >= 0; x--){
                    value += sharedOriginal[y * w + x];
        __syncthreads();
if(col < width && row < height)</pre>
    result[row * width + col] = value;
```



Utilizzo della shared memory - 2

```
if(bx < bx)
            _{x} = w-1;
        else{
            _x = tx;
        if(_by < by){
            _{y} = h-1;
        else{
            _y = ty;
        if(col < width && row < height){</pre>
            for(int y = _y; y >= 0; y--){
                 for(int x = _x; x >= 0; x--){
                     value += sharedOriginal[y * w + x];
        __syncthreads();
if(col < width && row < height)</pre>
    result[row * width + col] = value;
```

copia del valore definitivo nella global memory



Parallelizzazione al "primo livello"

```
#proid generateIntegralCPUompFirstLevel(int width, int height, int const * original, int * result, int threads){
#pragma omp parallel for collapse(2) default(none) shared(original, result) firstprivate(width, height) \
num_threads(threads)

for(int row = 0; row < height; row++){

for(int col = 0; col < width; col++){

    int value = 0;

    for(int y = row; y >= 0; y--){

        for(int x = col; x >= 0; x--){

            value += original[y * width + x];

        }

        result[row * width + col] = value;
}
```



Parallelizzazione al "primo livello"



Parallelizzazione al "secondo livello"



Parallelizzazione al "secondo livello"

parallel for con reduction



Parallelizzazione ad "entrambi i livelli"

```
void generateIntegralCPUompBothLevels(int width, int height, int const * original, int * result, int threads1, int threads2){
#pragma omp parallel for collapse(2) default(none) shared(original, result) firstprivate(width, height, threads2) \
num_threads(threads1)

for(int row = 0; row < height; row++){
    for(int col = 0; col < width; col++){
        int value = 0;

#pragma omp parallel for collapse(2) default(none) shared(original) firstprivate(row, col, width) \
num_threads(threads2) reduction(+: value)

for(int y = row; y >= 0; y--){
    for(int x = col; x >= 0; x--){
        value += original[y * width + x];
    }

}

result[row * width + col] = value;
}
}
```



Parallelizzazione ad "entrambi i livelli"



Test

integral_image_cuda ▲ CMakeLists.txt almageControllerGPU.cu # ImageControllerGPU.cuh all IntegralGeneratorPar.cu IntegralGeneratorPar.cuh all IntegralGeneratorSeq.cu IntegralGeneratorSeq.cuh main.cu integral_image_omp ▲ CMakeLists.txt # ImageController.cpp # ImageController.h IntegralGeneratorOMP.cpp IntegralGeneratorOMP.h amain.cpp

report # Image.h i test si trovano nei due file main



Test

```
integral_image_cuda
     ▲ CMakeLists.txt
     ImageControllerGPU.cu
     ImageControllerGPU.cuh
     IntegralGeneratorPar.cu
     IntegralGeneratorPar.cuh
     IntegralGeneratorSeq.cu
     IntegralGeneratorSeq.cuh
     # main.cu
integral_image_omp
     ▲ CMakeLists.txt
     # ImageController.cpp
     # ImageController.h
     # IntegralGeneratorOMP.cpp
     IntegralGeneratorOMP.h
     amain.cpp
    report
  # Image.h
```

```
__host__ double CPU_sequential(Image const &original, Image &result){...}
__host__ double GPU_globalMem(Image const &original, Image &result, dim3 grid, dim3 block){...}
__host__ double GPU_sharedMem(Image const &original, Image &result, dim3 grid, dim3 block){...}
__host__ void dimTest(std::string const &testName){...}
__host__ void gridTest(std::string const &fileName, int d, int GB[4][4]){...}
__host__ void gridTest1(std::string const &testName){...}
__host__ void gridTest2(std::string const &testName) {...}
int main(int argc, char *argv[]) {
   if(argc != 2){
        printf( Format: "Manca il parametro\n");
        return 1;
    std::string testName = argv[1];
    dimTest(testName);
    gridTest1(testName);
   gridTest2(testName);
    return 0;
```

```
idouble CPU_omp(Image const &original, Image &result, int * threads, int level){...}
ivoid dimTest(std::string const &testName, double * time){...}
ivoid threadsTest(std::string const &testName){...}
int main(int argc, char *argv[]) {
    if(argc != 2){
        printf( format "Manca il parametro\n");
        return 1;
    }
    omp_set_nested(4);
    std::string testName = argv[1];
    threadsTest(testName);
    threadsTestV2(testName);
    return 0;
}
```



Test 1 v1 - CUDA

Studio sulle dimensioni di grid e block (casi limite)

- dimensione immagine = $\{10x10, 100x100, 1000x1000\}$
- dimensione grid e block come nella tabella

		dim	dim	dim
		10x10	100x100	1000x1000
righe	grid	1x10	1x100	1x1000
right	block	10x1	100x1	1000x1
colonne	grid	10x1	100x1	1000x1
Colonne	block	1x10	1x100	1x1000
max n°	grid	10x10	100x100	255x255
blocks	block	1x1	1x1	4x4
max n°	grid	1x1	4x4	32x32
threads	block	10x10	32x32	32x32

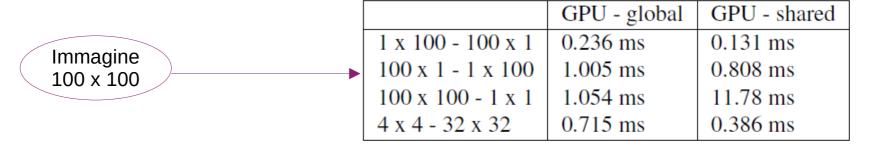




Test 1 v1 - CUDA

Studio sulle dimensioni di grid e block (casi limite)

	GPU - global	GPU - shared	
1 x 10 - 10 x 1	0.047 ms	0.039 ms	Immagine
10 x 1 - 1 x 10	0.041 ms	0.046 ms	10 x 10
10 x 10 - 1 x 1	0.056 ms	0.061 ms	
1 x 1 - 10 x 10	0.042 ms	0.038 ms	



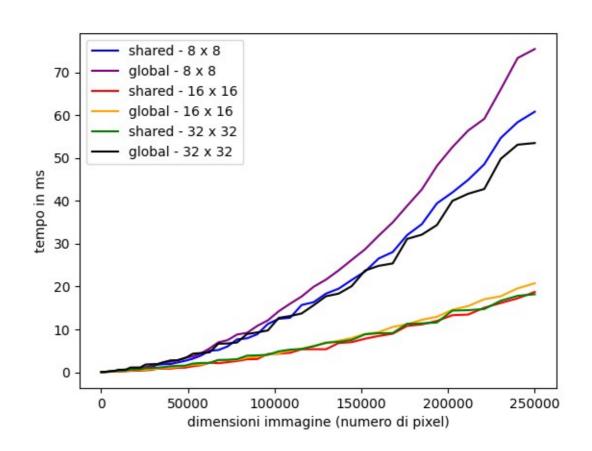
1 x 1000 - 1000 x 1 1000 x 1 - 1 x 1000 255 x 255 - 4 x 4 32 x 32 - 32 x 32
--



Test 1 v2 - CUDA

Studio sulle dimensioni di grid e block (numero di thread multiplo di 32) global memory & shared memory

- dimensione immagine che varia da 10x10 a 500x500 (aumentando il lato di 10 in 10)
- dimensione block = $\{8x8, 16x16, 32x32\}$





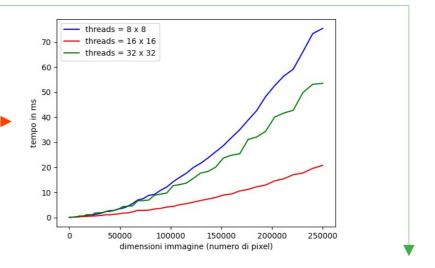
Test 1 v2 - CUDA

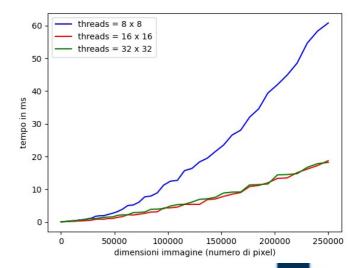
Studio sulle dimensioni di grid e block (numero di thread multiplo di 32)

global memory & shared memory

• dimensione immagine che varia da 10x10 a 500x500 (aumentando il lato di 10 in 10)

• dimensione block = $\{8x8, 16x16, 32x32\}$



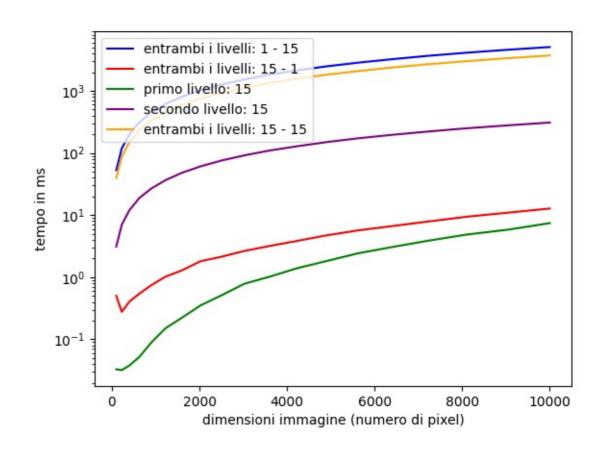




Test 2 v1 - OpenMP

Studio sul tipo di parallelizzazione migliore

- dimensione dell'immagine che varia da 10x10 a 100x100 (aumentando il lato di 5 in 5)
- livelli e thread:
 - entrambi i livelli, 1 e 15 thread
 - entrambi i livelli, 15 e 1 thread
 - primo livello, 15 thread
 - secondo livello, 15 thread
 - entrambi i livelli, 15 e 15 thread

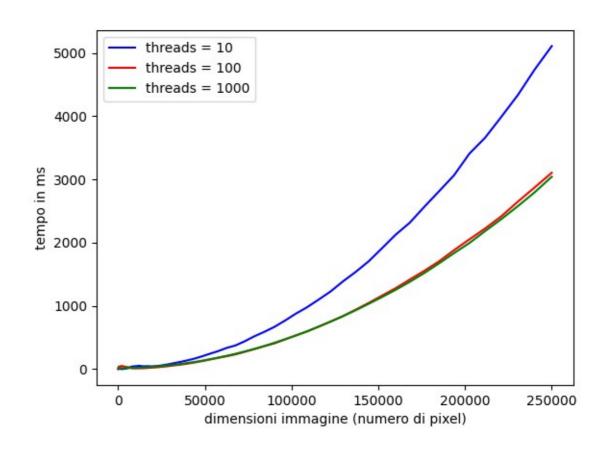




Test 2 v2 - OpenMP

Aumento del numero di thread (primo livello)

- dimensione dell'immagine che varia da 10x10 a 500x500 (aumentando il lato di 10 in 10)
- numero di thread = {10, 100, 1000}





Test 3

Aumento della dimensione dell'immagine

- dimensione dell'immagine che varia da 10x10 a 500x500 (aumentando il lato di 10 in 10)
- OpenMP primo livello con 100 thread
- CUDA shared memory con dimensione dei block = 16x16

